当代人工智能 实验一：新闻文本十分类实验报告

GitHub 代码仓库：https://github.com/Feiyu37yyc16/ai-lab1-text-classification
（提交前请替换为本人仓库地址）

一、实验目的与任务

在英文新闻邮件数据集上完成十分类任务，掌握“数据划分—文本预处理—TF-IDF 特征提取—模型训练—验证集调参—测试集预测”的完整监督学习流程。实验要求至少实现两种分类算法、在验证集上比较不同模型与参数，选定最优模型后对 2457 条无标签测试样本进行预测，并提交 prediction.csv。

二、数据与实验设置

项目	说明
训练集 / 测试集	7368 条带标签训练样本 / 2457 条无标签测试样本；10 个类别，每类 705 - 747 条，类别基本均衡
文本形态	英文网络新闻邮件，含 From、Subject、Organization、Lines、NNTP-Posting-Host 等邮件头，正文长度中位数 170 词
验证集划分	按 80%/20% 分层抽样（stratified split）得到 5894 条训练 / 1474 条验证，random_state=42，测试集全程封存
评价指标	验证集准确率 Accuracy 与宏平均 F1（macro-F1），并报告每类精确率、召回率、F1 与混淆矩阵
可复现性	固定随机种子 42；Python 3.10、scikit-learn 1.9.1；同一向量化与清洗规则仅在训练数据上拟合，再应用于验证/测试集

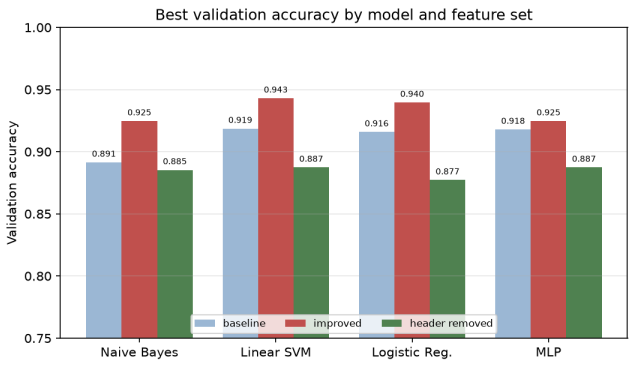
三、方法：特征工程与模型

TF-IDF 特征。设置三组对照特征：① baseline 复现示例代码，原始文本仅取词频最高的 5000 个 unigram；② improved 保留原文，使用 unigram+bigram（ngram_range=(1,2)、min_df=2、max_df=0.95）并启用次线性词频 sublinear_tf，维度 211709；③ header_removed（消融）
先正则清洗邮件头、引用行、邮箱、网址、数字与标点并移除英文停用词，再以相同方式提取，维度 81711。
分类模型。实现四种模型：多项式朴素贝叶斯（MultinomialNB，基于贝叶斯定理与条件独立假设）；线性支持向量机（LinearSVC，在高维词项空间中学习最大间隔超平面）；逻辑回归（softmax 多项逻辑回归，lbfgs 求解、L2 正则）；多层感知机（MLP，ReLU 隐层，early stopping）。网格设置：NB 的 alpha∈{0.01,0.05,0.1,0.3,0.5,1.0}；SVM 的 C∈{0.01,0.05,0.1,0.3,0.5,1,3,5}；LR 的 C∈{0.1,0.5,1,3,5,10,100}；MLP 比较 (100,)/(100,50) 隐层与 alpha∈{1e-4,1e-2}。所有模型×特征组合均在同一验证集上评估，再选取全局最优配置。

四、实验结果

模型	baseline Acc / F1	improved Acc / F1	header_removed Acc / F1	improved 最优参数	训练耗时
朴素贝叶斯	0.891 / 0.892	0.925 / 0.926	0.885 / 0.886	alpha=0.01	0.06 s
线性 SVM	0.919 / 0.919	0.943 / 0.943	0.887 / 0.888	C=1.0	1.55 s
逻辑回归	0.916 / 0.916	0.940 / 0.940	0.877 / 0.878	C=100	14.9 s
MLP	0.918 / 0.918	0.925 / 0.926	0.887 / 0.888	(100,), α=1e-4	352 s

表 1 四种模型在三组特征上的最优验证集结果（全局最优：LinearSVC + improved，Acc=94.30%，macro-F1=0.9431）



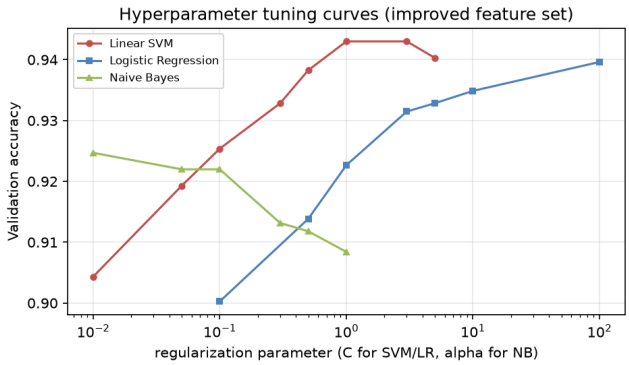
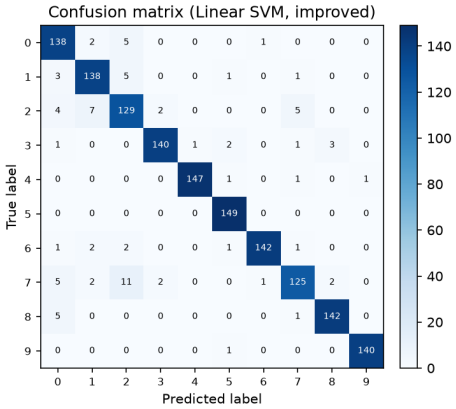


图 1 各模型×特征集最优验证准确率 图 2 improved 特征上的调参曲线（横轴为对数尺度）

五、结果分析



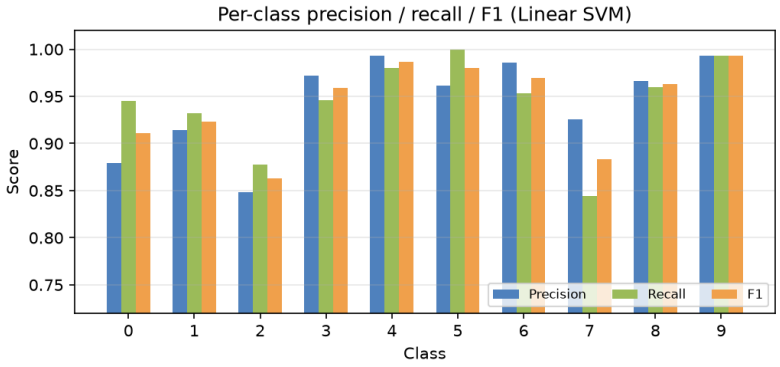


图 3 最优模型验证集混淆矩阵 图 4 最优模型每类 Precision / Recall / F1

① 模型比较。线性 SVM 与逻辑回归显著领先（94.3%、94.0%），朴素贝叶斯与 MLP 均为 92.5%。TF-IDF 把文本映射到 21 万维稀疏空间，样本数（5894）远小于特征数，文档在此空间中近似线性可分，最大间隔分类与 L2 正则恰好抑制了高维过拟合；MLP 虽具非线性能力，但训练耗时约为 SVM 的 230 倍（352 s vs 1.55 s），且未带来收益。

② 特征工程。加入 bigram 与 sublinear TF 后，SVM 由 91.9% 提升至 94.3%，NB 由 89.1% 提升至 92.5%，说明“not good”“x ray”等搭配短语携带了强判别信息；调参曲线（图 2）显示 SVM 在 C=1～3 处达峰，C=0.01 时欠拟合（90.4%）、C=5 时轻微回落（94.0%），而 LR 随 C 增大持续改善至 C=100。

③ 邮件头消融（独立思考）。去除邮件头后所有模型一致下降约 5 个百分点（SVM 94.3%→88.7%）。原因是 Organization、NNTP-Posting-Host 与邮箱域名等元数据与新闻组类别高度相关（如特定机构域名反复出现在特定组），模型学到了“发件人身份”这一捷径而非正文主题。这是一种典型的元数据泄露：保留邮件头能在该固定数据集上拿到更高数字，但属于不可迁移的虚假信号，对新来源邮件的泛化能力更差，因此准确率并非唯一追求。

④ 错误分析。10 类中 9 类 F1 超过 0.91，类 9、4、5 最优（F1≥0.98）；类 2、7 最差（F1 0.863、0.883），混淆矩阵显示二者互相误判最多（11 条类 7→类 2、5 条类 2→类 7），说明二者主题词汇高度重叠；类 0 精确率最低（0.879），主要被误判为类 7。

六、思考与扩展

1）SVM/逻辑回归为何在文本上表现好？ 文本经 TF-IDF 表示后高维、稀疏、近线性可分，线性模型在该空间中表达能力充足且泛化稳定；核 SVM 与神经网络的非线性优势无从发挥，反而更易过拟合。

2）MLP 能否通过加深加宽提升？ 本实验中 (100,50) 两层网络反而降至 92.0%，因 21 万维输入 × 数千样本使参数量远超样本量；可尝试 Truncated SVD（LSA）先降维、Dropout、更强 alpha 与早停来缓解过拟合。

3）其他文本表示：词袋（Bag-of-Words，仅计数、无权重）、Word2Vec/GloVe（稠密低维、捕获语义相似但丢失词序）、BERT 等预训练模型（上下文相关表示，通常为当前 SOTA，但算力与部署成本远高于本实验的 TF-IDF 线性方案）。

七、创新点与结论

创新点：① 设计 baseline / improved / header_removed 三组对照特征，量化并解释了邮件头元数据泄露现象；② 使用 unigram+bigram 与次线性词频，系统网格搜索 20 余组参数；③ 输出混淆矩阵、每类指标与调参曲线完成完整错误分析；④ 对清洗后为空的 10 条样本做原文回退，保证流程鲁棒。结论：在统一数据、指标与随机种子下，bigram TF-IDF + 线性 SVM（C=1）以 94.30% 的验证准确率、约 1.5 秒的训练成本取得最优综合表现，已用该配置在全部 7368 条训练数据上重新训练，并对 2457 条测试样本输出 prediction.csv。局限性：类别 2/7 仍需更细粒度语义特征；仅用单一验证划分，未做多折交叉验证估计结果波动。